



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضانی

طراح سوالات : علی معینیان

سلام به همه دانشجویان عزیز 🖐️

👉 پیش از شروع سوالات لطفاً به این دو قانون توجه کنید:

- ۱: در صورت مشاهده هرگونه تقلب، ۲ برابر امتیاز آن سوال از نمره کلی تمرین کسر خواهد شد.
- ۲: در صورتی که از هوش مصنوعی برای پاسخگویی استفاده میکنید، حتما در منابع ذکر کنید.
- ۳: با توجه به سنگین بودن برخی قسمت‌های این تمرین، پیشنهاد می‌کنم از Google Colab استفاده کنید و از GPU استفاده کنید.

👉 فایل نهایی پاسخ شما باید شامل فایل‌های زیر باشد:

۱: فایل داکيومنت پاسخ به سوالات تشریحی

۲: نوت بوک پاسخ به سوال عملی

نام گذاری فایل‌های شما باید به شکل زیر باشد:

Name – StudentID - Name - NLP - HW1

👉 راهنمایی دانلود Library های مورد نیاز:

می‌توانید کتابخانه‌های مورد نظر را با استفاده از دستور زیر دانلود کنید :

pip install [LibraryName]



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضائی

طراح سوالات: علی معینیان

سوالات تشریحی فصل اول ----- ۳+ نمره

۱: تفاوت Stemming و Lemmatization را توضیح دهید. با استفاده از جمله زیر، خروجی هر دو روش را بنویسید. (۵ نمره)

The cats are running faster every day

۲: مفهوم Retrieval-Augmented Generation یا همان RAG را با ذکر سه مرحله اصلی توضیح دهید. چرا استفاده از RAG نسبت به استفاده مستقیم از یک LLM برای سیستم های سازمانی مناسب تر است؟ (۵ نمره)

۳: دو مفهوم Extractive QA و Generative QA را مقایسه کنید و برای هر کدام یک سناریو واقعی مثال بزنید. (۵ نمره)

۴: فرض کنید می خواهید یک سیستم QA برای پاسخ به سوالات پزشکی بسازید. بین این دو رویکرد، کدام را انتخاب می کنید؟ ۳ معیار زیر را در پاسخ نهایی خود در نظر بگیرید: (۵ نمره)

- ریسک توهم مدل در حوزه پزشکی
- نیاز به traceability
- مسئله No-Answer در مواردی که اطلاعات کافی وجود ندارد.

۵: فرض کنید می خواهید یک سیستم Question-Answering برای پشتیبانی مشتریان سایت Numberland بسازید. با توجه به مفاهیمی که در فصل اول خواندید: (۵ نمره)

سایت [Numberland](#) از معروف ترین سایت هایی است که خدماتی از جمله شماره مجازی، خرید اکانت های هوش مصنوعی، خرید گیفت کارت و اکانت پرمیوم (مانند Spotify و ...) را برای کاربران ایرانی انجام می دهد. **حتما قبل از پاسخ به سوال، به این سایت سر بزنید تا با فعالیت آن ها به طور دقیق تر آشنا شوید.**

- معماری Pipeline پیشنهادی خود را رسم کنید.
- توضیح دهید در هر مرحله از Pipeline چه وظیفه ای انجام می شود.
- یک چالش فنی و یک چالش اخلاقی احتمالی در این سیستم را ذکر و تحلیل کنید.

۶: تفاوت Multilingual NLP با Cross-Lingual NLP را با ذکر مثال توضیح دهید. در پاسخ خود به موارد زیر اشاره کنید: (۵ نمره)

- تعریف دقیق هر رویکرد و هدف آن
- مثال واقعی برای هر رویکرد (مثلاً یک مدل یا پروژه شناخته شده)
- مقایسه از نظر نیاز به داده labeled در هر زبان



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضانی

طراح سوالات : علی معینیان

سوالات تشریحی فصل دوم ----- ۱۵ نمره

۱: اصل "Garbage In, Garbage Out" در پیش‌پردازش NLP به چه معناست؟ با ذکر دو مثال واقعی توضیح دهید که چگونه عدم انجام یک مرحله پیش‌پردازش خاص (مثلاً حذف نویز یا نرمال‌سازی) می‌تواند عملکرد مدل را در یک تسک خاص مانند تحلیل احساسات یا طبقه‌بندی متن تخریب کند. (۵ نمره)

۲: چرا مدل‌های زبانی مدرن مانند BERT و GPT از Subword Tokenization استفاده می‌کنند؟ مزایا و معایب سه سطح Tokenization را از سه منظر زیر مقایسه کنید و جدول را کامل کنید: (۵ نمره)

Subword Level	Word Level	Character Level	معیار
			اندازه Vocabulary
			مدیریت کلمات OOV
			هزینه محاسباتی

۳: مشکل Out-Of-Vocabulary (OOV) چیست و چرا در مدل‌های مبتنی بر Word-Level Tokenization بحرانی‌تر است؟ سه راه‌حل برای مدیریت OOV را نام ببرید و توضیح دهید چرا الگوریتم‌هایی مانند BPE یا WordPiece این مشکل را به‌طور موثر کاهش می‌دهند. (۵ نمره)



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضانی

طراح سوالات : علی معینیان

بخش عملی ----- ۵۵ نمره

شما به تازگی به تیم تحلیل داده یک استارتاپ نظارت بر شبکه های اجتماعی پیوسته اید. ماموریت شما در حال حاضر تحلیل توییت های ایلان ماسک است. و هدف شما، استخراج الگوهای زبانی، موجودیت ها و آماده سازی داده ها برای مدل های طبقه بندی احساسات است.

ابتدا دیتاست توییت های ایلان ماسک را [دانلود](#) کنید. همچنین شما میتوانید از کتابخانه های زیر استفاده کنید :

Pandas, NumPy, re, NLTK, spaCy, sklearn, transformer, seaborn, matplotlib

پیش پردازش، هنر تعادل است، بین حذف نویز و حفظ معنا، بین ساده سازی و از دست دادن داده ها!
در هر مرحله از خود بپرسید: آیا این تغییر، مدل نهایی را به درک بهتری از زبان نزدیک تر می کند؟

بخش یک: بارگذاری و اکتشاف اولیه داده ها (۵ نمره)

- دیتاست را با pandas بارگذاری کنید و ۵ رکورد اول را نمایش دهید .
- اطلاعات کلی دیتاست را گزارش دهید مانند shapes و dtype و تعداد مقادیر null یا miss در هر ستون
- توزیع طول توییت ها را از نظر تعداد کاراکتر (روی ستون text خام) با یک هیستوگرام رسم کنید. محور x و y را برچسب بزنید .
- ۳ توییت با بیشترین طول و ۳ توییت با کمترین طول را چاپ کنید.
- توزیع ستون های favorites و retweets را با boxplot یا هیستوگرام رسم کنید و میانه و میانگین آن ها را گزارش دهید.

بخش دو: پاک سازی و نرمال سازی متن (۱۰ نمره)

ابتدا یک کپی از ستون text با نام original_tweet ایجاد کنید. تمام تبدیل های زیر را روی ستون جدید اعمال کنید و original_tweet را دست نزنید.

مراحل پاک سازی را به ترتیب اعمال کنید:

- تبدیل HTML entities به متن معمولی (به این روش HTML Decoding هم میگویند)
- تمام متن باید lowercase شود
- حذف لینک های http/https و لینک های کوتاه شده t.co با Regex
- حذف Mention و Hashtag
- حذف کاراکترهای خاص و ایموجی ضمن حفظ علائم نگارشی مهم مانند ! و ؟
- مدیریت اعداد : اعداد ساده را با توکن <NUM> جایگزین کنید.
- **توجه: اعداد همراه با واحد مثل 3M، 44B، 78% را در این مرحله دست نزنید**
- نرمال سازی فاصله : حذف extra whitespace و trim متن.



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضانی

طراح سوالات : علی معینیان

پس از پاکسازی، تعداد توییت‌های خالی یا بسیار کوتاه (زیر ۳ کاراکتر) را گزارش دهید و توضیح دهید با آن‌ها چه کار می‌کنید.

بخش سه: استخراج الگوها با Regular Expressions (۵ نمره)

تمام موارد زیر را از ستون original_tweet استخراج کنید، نه cleaned_tweet؛ چون پاکسازی بخش ۲ هشتک‌ها، URL‌ها و اعداد را حذف کرده است.

با استفاده از ماژول re در پایتون، الگوهای Regex مناسب بنویسید و نتایج را در ستون‌های جدید ذخیره کنید.

- هشتک‌های انگلیسی
- اعداد همراه واحد مانند K و M و T و ...
- درصدها
- آدرس‌های ایمیل

برای هر مورد، Regex Pattern خود را توضیح دهید و نمونه خروجی واقعی نمایش دهید.

بخش چهار: Tokenization (۵ نمره)

100 توییت را به صورت تصادفی با random_state=42 از ستون cleaned_tweet انتخاب کنید و سه روش زیر را پیاده‌سازی کنید:

- Whitespace Tokenization تقسیم ساده با str.split()
- Word Tokenization با nltk.word_tokenize()
- Subword Tokenization با BertTokenizer

برای هر روش موارد زیر را محاسبه کنید:

- میانگین تعداد توکن به ازای هر توییت
- اندازه واژگان منحصربه‌فرد (unique vocabulary)
- نرخ کلمات OOV

یک نمونه توییت را انتخاب کنید و خروجی هر سه روش را کنار هم نشان دهید. سپس نتایج را در یک جدول مقایسه‌ای رسم کنید و در ۳ تا ۵ جمله تحلیل کنید کدام روش برای task تحلیل احساسات توییت‌های انگلیسی مناسب‌تر است و چرا.

بخش پنج: نرمال سازی واژگان (۵ نمره)

پیش از اجرای Lemmatization، به POS tag هر کلمه نیاز دارید. این تگ‌گذاری را در همین بخش انجام دهید، یا می‌توانید از spaCy که هر دو را یکجا انجام می‌دهد استفاده کنید.

روی ستون cleaned_tweet دو عملیات زیر را انجام دهید:



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضانی

طراح سوالات : علی معینیان

• **Stemming** با الگوریتم Porter Stemmer از NLTK

• **Lemmatization** با WordNetLemmatizer از NLTK به همراه POS Tagging یا pipeline کامل spaCy

برای هر روش گزارش دهید:

• اندازه واژگان قبل و بعد از اعمال روش و درصد کاهش

• چند مثال از کلماتی که دو روش نتایج متفاوتی روی آن‌ها تولید کرده‌اند

بخش شش: پیش پردازش پیشرفته (۱۰ نمره)

بخش الف: POS Tagging

با استفاده از spaCy، تگ POS را به هر توکن اختصاص دهید.

• درصد توزیع تگ‌های اصلی NOUN، VERB، ADJ، ADV، PROPON در کل دیتاست محاسبه و با یک bar chart نمایش دهید.

• تحلیل کنید: نسبت NOUN به VERB در توییت‌ها چه چیزی درباره سبک نوشتاری ایلان ماسک می‌گوید؟

بخش ب: Named Entity Recognition (NER)

• موجودیت‌های نامدار را از کل دیتاست استخراج کنید.

• فرکانس هر نوع موجودیت PERSON، ORG، GPE، MONEY را گزارش کنید

• ۵ موجودیت پرتکرار هر نوع را نام ببرید.

بخش هفت: ارزیابی نهایی Pipeline پیش پردازش (۱۵ نمره)

هدف این بخش، مشاهده تاثیر مستقیم پیش‌پردازش شما روی عملکرد یک مدل یادگیری ماشین واقعی است. از آنجا که دیتاست توییت‌های ایلان ماسک برچسب احساسات ندارد، از یک رویکرد هوشمندانه استفاده می‌کنیم: پیش‌بینی محبوبیت توییت!

مدل از روی متن تمیزشده توییت پیش‌بینی می‌کند آیا آن توییت در ۲۵٪ پرایک‌ترین توییت‌ها قرار می‌گیرد یا خیر. هرچه پیش‌پردازش شما بهتر باشد، ویژگی‌های معنادارتری استخراج شده و دقت مدل بالاتر می‌رود.

در انتهای نوت‌بوک خود، یک سلول جدید ایجاد کنید و **کد ارزیابی** را دقیقاً و بدون هیچ‌گونه تغییری کپی و اجرا کنید. این کد دیتافریم شما را دریافت کرده، روی ستون cleaned_tweet یک مدل Logistic Regression آموزش می‌دهد و دقت آن را روی یک مجموعه تست با seed ثابت می‌سنجد.

نکات مهم:



دانشگاه اصفهان

درس پردازش زبان طبیعی (NLP)

پروژه فصل اول و دوم

دکتر رضا رضانی

طراح سوالات : علی معینیان

- پیش از اجرای کد، مطمئن شوید که تمام مراحل پاک‌سازی را روی ستون `cleaned_tweet` اعمال کرده‌اید و مقادیر `Null` مدیریت شده‌اند.
- مطمئن شوید نام دیتافریم نهایی شما در آخرین خط کد صحیح است. اگر نام دیتافریم تمیزشده‌ی شما `df_clean` است، آرگومان اول را به `df_clean` تغییر دهید. اگر نام آن `df` است، همان را نگه دارید.
- خروجی چاپ‌شده توسط این کد (دقت مدل) را در فایل داکيومنت گزارش خود وارد کنید و در دو تا سه خط توضیح دهید که به نظر شما چرا مدل توانسته یا نتوانسته به دقت بالایی برسد و کدام مرحله از پیش‌پردازش شما بیشترین تاثیر را داشته است.